

Машинное обучение

ФКН ВШЭ

Теоретическое домашнее задание №2

Задача 1. Найдите константу C , решающую следующую задачу ($0 < \tau < 1$ фиксировано):

$$\sum_{i=1}^{\ell} \rho_{\tau}(y_i - C) \rightarrow \min_C,$$
$$\rho_{\tau}(x) = \begin{cases} \tau x, & x > 0, \\ (\tau - 1)x, & x \leq 0. \end{cases}$$

Задача 2. Покажите, что если в задаче регрессии $p(y_i|x_i, w) = \frac{\alpha}{2} \exp(-\alpha|y_i - w^T x_i|)$ (распределение Лапласа, α фиксировано), то метод максимального правдоподобия эквивалентен оптимизации MAE для модели линейной регрессии.

Задача 3. Представим, что в некоторой задаче мы можем разбить признаки на k непересекающихся групп (например, такие группы возникают при использовании one-hot кодирования — по одной группе бинарных признаков на каждый категориальный признак). Кроме того, мы хотим в модели линейной регрессии задать свой ненулевой коэффициент L_2 —регуляризации для каждой группы. Какому априорному распределению на веса это будет соответствовать?

Задача 4. Убедитесь, что вы знаете ответы на следующие вопросы:

- Почему L_1 -регуляризация производит отбор признаков?
- Почему коэффициент регуляризации нельзя подбирать по обучающей выборке?
- Что такое кросс-валидация, чем она лучше использования отложенной выборки?
- Почему категориальные признаки нельзя закодировать натуральными числами? Что такое one-hot encoding?
- Для чего нужно масштабировать матрицу объекты-признаки перед обучением моделей машинного обучения?
- Почему MSE чувствительно к выбросам?
- Что такое Huber Loss? В чем его преимущества по сравнению с MAE и MSE?
- Почему квантильная регрессия так называется?