

Машинное обучение, ФКН ВШЭ

Домашнее задание №7

Задача 1 (2 балла). На лекции и семинаре был рассмотрен метод обратного распространения ошибки в общем случае. Рассмотрим частный случай с полносвязным слоем, у которого d_{in} входных и d_{out} выходных нейронов. В качестве функции активации используем сигмоидальную: $g(t) = \frac{1}{1+\exp(-t)}$.

В полносвязном слое i -й выходной нейрон для слоя l можно выразить следующим образом:

$$x_i^l = g\left(\sum_{j=1}^{d_{in}} w_{ij}^l x_j^{l-1} + b_i^l\right)$$

Требуется вычислить производную функции потерь $L(z, y)$ по весу w_{ij}^l полносвязного слоя l :

$$\frac{\partial L}{\partial w_{ij}^l}$$

Выражение может включать в себя величины, посчитанные во время прямого прохода по нейронной сети, и величины, полученные со следующих (по порядку прямого прохода) слоёв во время обратного прохода. Функция потерь дифференцируема по выходам сети z .

Задача 2 (4 балла). Рассмотрим вместо полносвязного слоя из задачи 1 свёрточный слой. Пусть на вход поступает изображение размера $H \times W$, свёрточный слой имеет размер $k_1 \times k_2$. Тогда применение свёрточного слоя можно выразить следующим образом:

$$x_{ij}^l = g\left(\sum_{m=0}^{k_1-1} \sum_{n=0}^{k_2-1} w_{mn}^l x_{i+m, j+n}^{l-1}\right)$$

Требуется вычислить производную функции потерь $L(z, y)$ по весу w_{mn}^l свёрточного слоя l :

$$\frac{\partial L}{\partial w_{mn}^l}$$

Выражение может включать в себя величины, посчитанные во время прямого прохода по нейронной сети, и величины, полученные со следующих (по порядку прямого прохода) слоёв во время обратного прохода. Функция потерь дифференцируема по выходам сети z .

Задача 3 (2 балла). С ростом количества слоёв нейронные сети могут выделять всё более сложные структуры в исходном пространстве признаков. Однако обучение глубоких нейронных сетей с помощью градиентных методов оптимизации вызывает некоторые сложности. Одной из таких проблем является проблема затухающих градиентов, когда градиенты для весов первых слоёв оказываются близкими к нулю, из-за чего первые слои обучаются медленнее последних. Подумайте и ответьте, почему так происходит. Предлагается рассматривать сигмоиду и гиперболический тангенс в качестве функции активации во всей сети.

Задача 4 (2 балла). Рассмотрим нелинейное преобразование ReLU:

$$g(x) = \begin{cases} x, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

Несмотря на свою простоту, оно позволяет сети выучивать сложную структуру и при этом легко вычисляется. Предлагается убедиться в нелинейности, подобрав коэффициенты сети для классификации с 2 входами и 1 выходом так, чтобы она выдавала ответы такие же, как функция XOR (нули на наборах из двух нулей и двух единиц, единицу на наборах с одной единицей). Также покажите, что для такой зависимости нельзя построить линейный классификатор, не допускающий ни одной ошибки.

Сеть должна иметь один скрытый слой из двух нейронов с активацией ReLU и одним выходным нейроном без нелинейного преобразования. Класс выдаваемый сетью определяется с помощью некоторого порога (например, 0.5, что эквивалентно при использовании сигмоидальной функции выбору класса с максимальной вероятностью). Свободных членов в сети нет. Достаточно найти любое подходящее решение.